Politechnika Warszawska

Algorytmy i struktury danych

Laboratorium 5

Projekt "Wyszukiwanie wzorca"

Informatyka – Inteligentne systemy

Paweł Sarnacki 305290

Piotr Niedziałek 304474

Prowadzący: dr inż. Łukasz Skonieczny

Warszawa 2023

1. Wstęp

Program został napisany w języku python z wykorzystaniem aplikacji Visual Studio Code. W programie zaimplementowane są trzy algorytmy wyszukiwania wzorca w tekście – algorytm N, KMP i KR. Poprawność działania algorytmów sprawdzono przy pomocy testów przypadkami brzegowymi. Pomiary wydajności zostały przeprowadzone poprzez wyszukiwanie ‘n’ pierwszych słów z tekstu „pan-tadeusz.txt”, gdzie n=100, 200, …, 1000. Program był pisany w wersji python 3.9.13, a wykorzystane biblioteki to: time, random, string, matplotlib, unidecode, re.

2. Struktura projektu

Projekt składa się z:

- Pliku main.py, który zawiera główny program wywołujący funkcje z plików i mierzący czas (Paweł Sarnacki, Piotr Niedziałek)
- Pliku file.py, w którym zaimplementowane jest wczytywanie słów z pliku tekstowego (Piotr Niedziałek)
- Pliku N.py, w którym zaimplementowany jest algorytm naiwnego wyszukiwania wzorca (Paweł Sarnacki)
- Pliku KMP.py, w którym znajduje się implementacja algorytmu Knutha-Morissa-Pratta (Piotr Niedziałek)
- Pliku KR.py, który posiada implementację algorytmu Karpa-Rabina (Paweł Sarnacki)
- Pliku test.py, w którym przeprowadzone są testy jednostkowe (Paweł Sarnacki, Piotr Niedziałek)
- Pliku plot.py, który zawiera implementację rysowania wykresów, są one zapisywane w katalogu plots (Paweł Sarnacki)

3. Uruchomienie projektu z środowiska Visual Studio Code

3.1. Otworzenie folderu, wybór ścieżki i kliknięcie wybierz folder

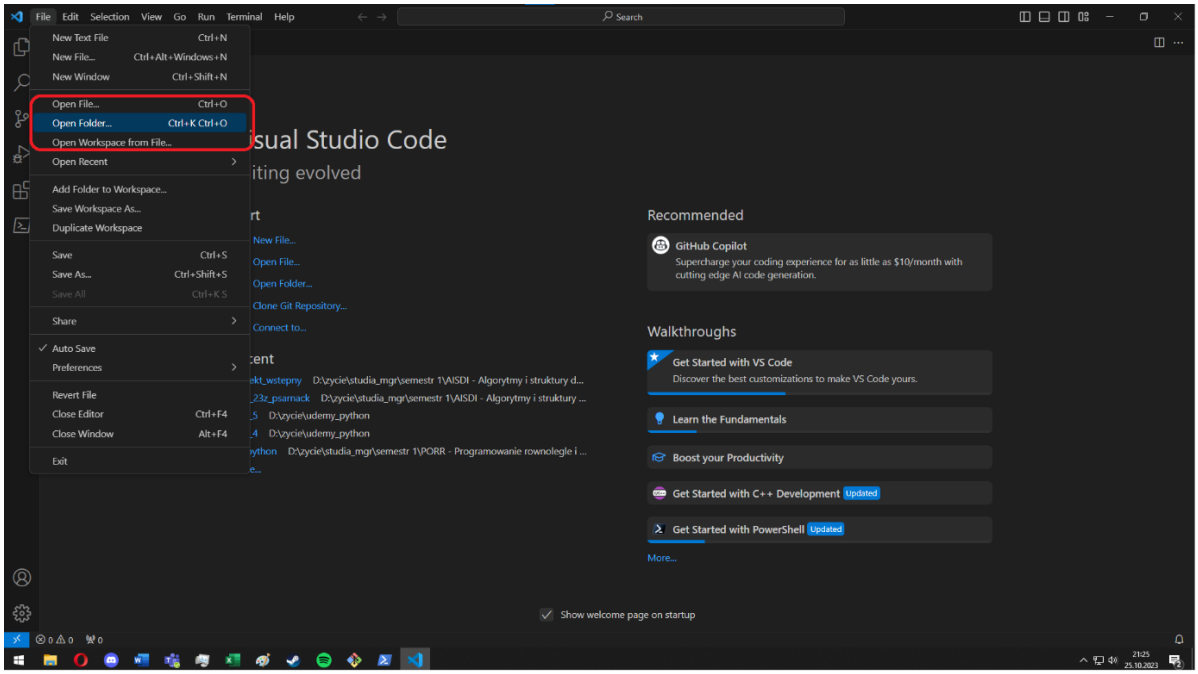

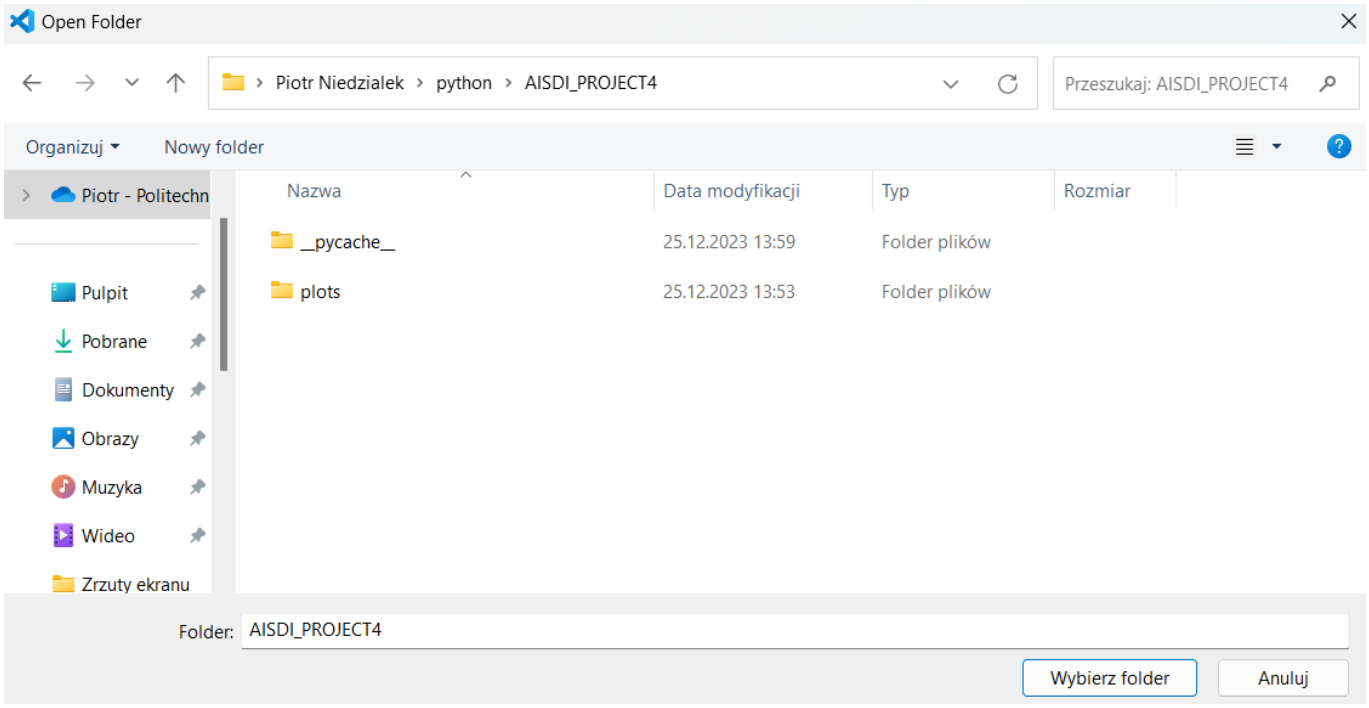

3.2. Wybranie terminalu bash, wpisanie „py main.py” lub „py test.py” do wykonania testów, lub kliknięcie F5, wyświetlony i zapisany zostanie wykres

4. Uruchomienie projektu bez środowiska Visual Studio Code

Przejście do odpowiedniego folderu z plikami projektu i wpisanie w cmd „py main.py” lub „py test.py”.

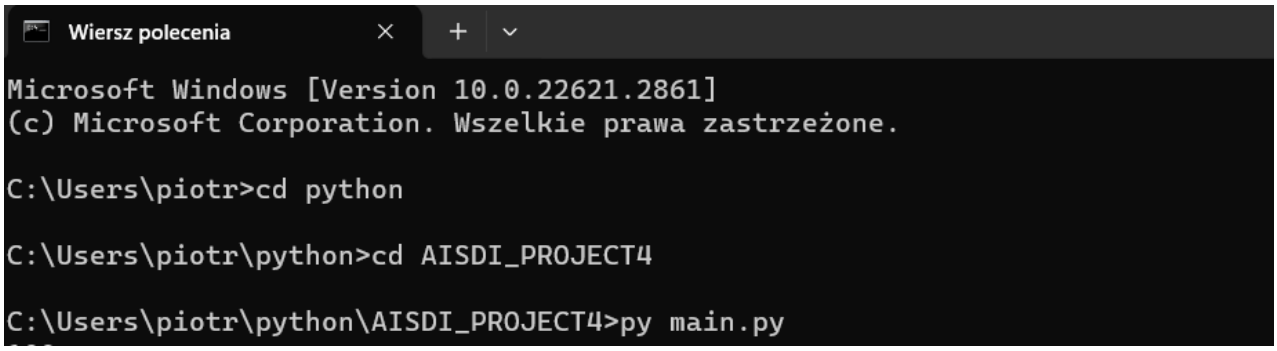

5. Otrzymane wyniki.

Wyniki testów:

- dla każdego algorytmu przeprowadzono testy dla przypadków brzegowych typu wyszukiwanie pustego wzorca, wyszukiwanie w pustym tekście etc.

- następnie przeprowadzono 100 testów na losowych wyrazach z alfabetu {a,b} i porównano wyniki algorytmów KR i KMP z algorytmem naiwnym

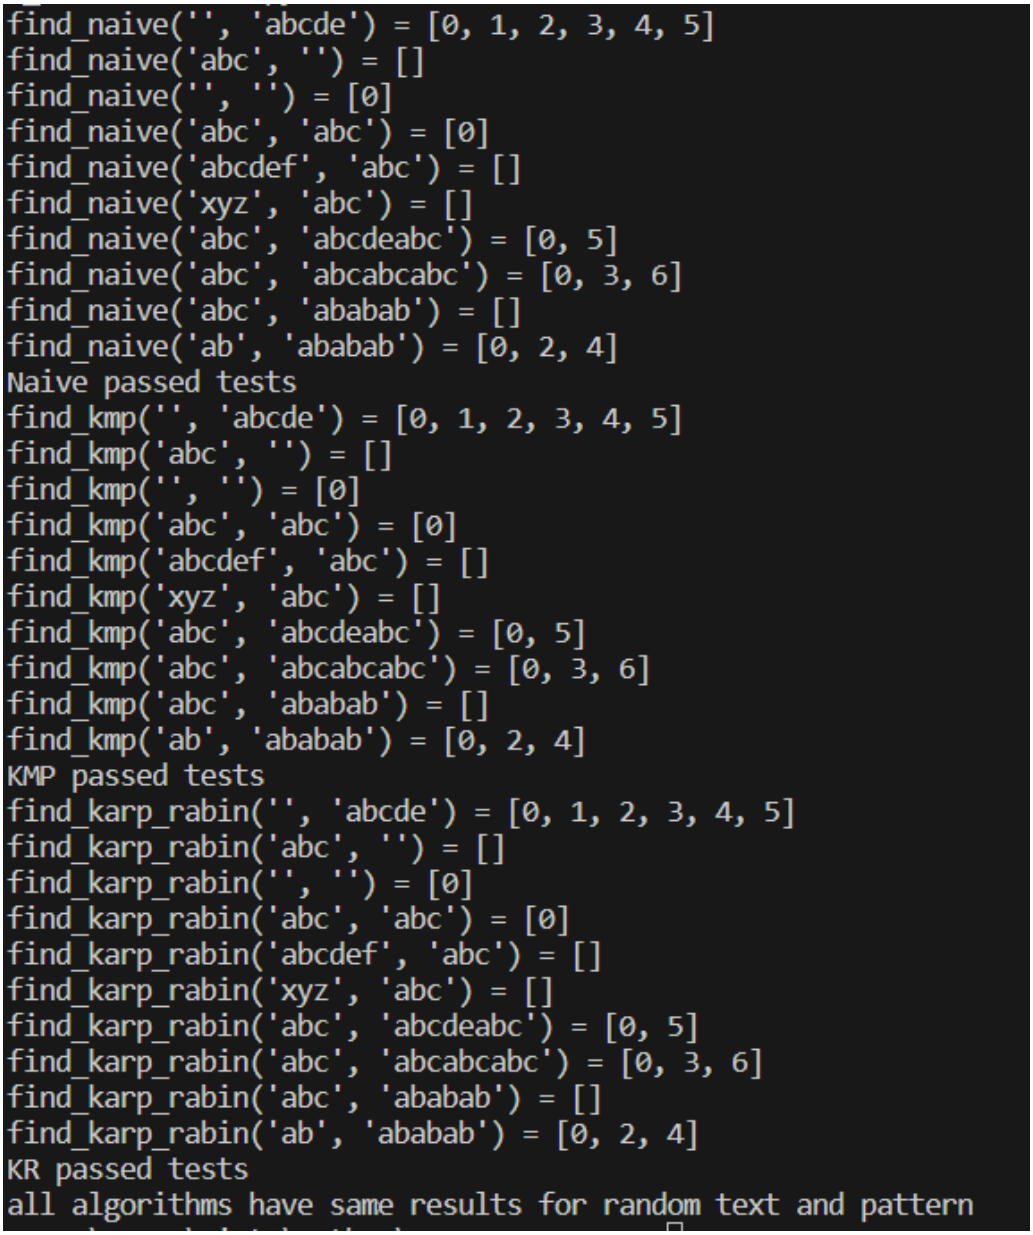

Wszystkie algorytmy przeszły testy przypadków brzegowych.

Dla losowych wyrazów wszystkie algorytmy dały te same rezultaty.

Zbiorczy wykres pokazujący zależność czasu wyszukiwania od liczby szukanych słów:

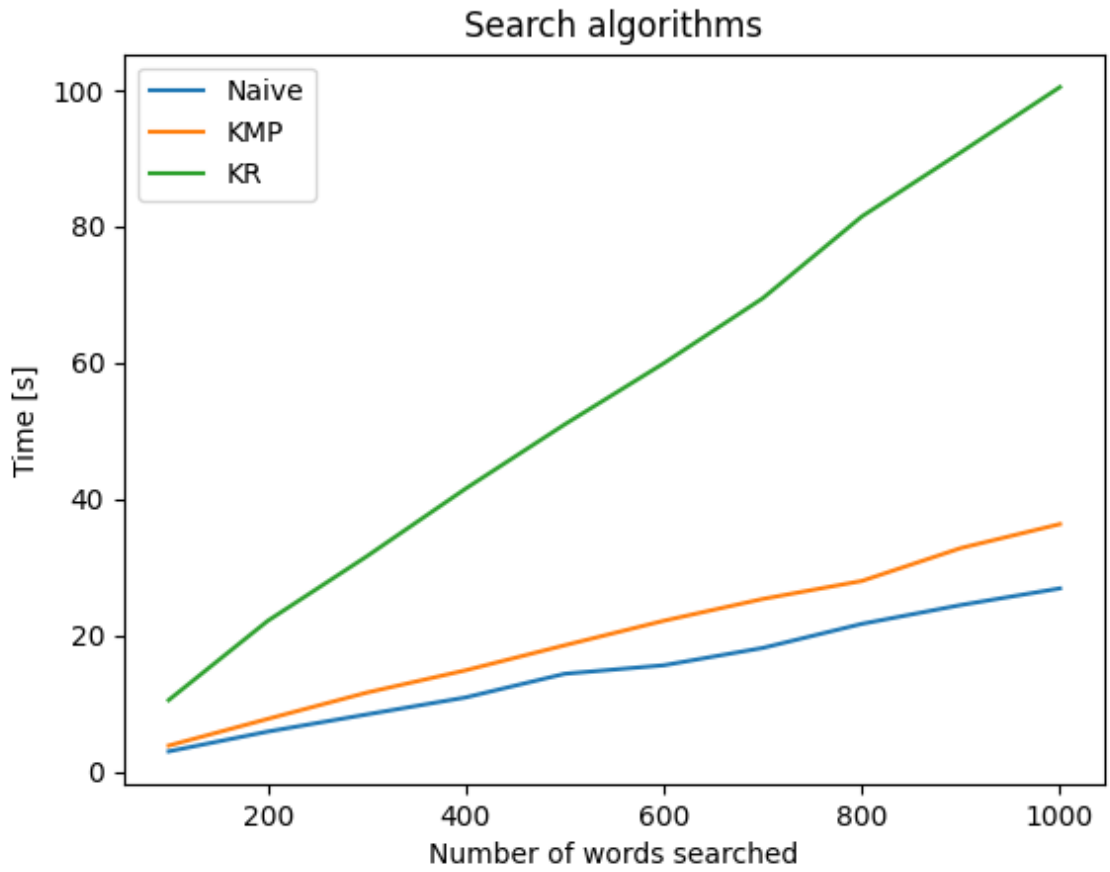

6. Wnioski

- dla tego przypadku algorytm naiwny okazał się najskuteczniejszy, dzieje się tak ponieważ algorytmy KMP i KR najskuteczniejsze są dla wyszukiwania długich wzorców, w innym przypadku koszt preprocesingu może przewyższać zysk czasu w wyszukiwaniu

- czas wyszukiwania KMP i algorytmu naiwnego jest podobny, zgadza się to z teorią – złożoność KMP to O(n+m), gdzie m to długość wyrazu, dla algorytmu naiwnego najgorszy przypadek to O(mn) ale zazwyczaj w normalnych tekstach jest to również O(m+n)

- w najgorszym przypadku algorytm KR ma złożoność O(mn+m), stąd wynika jego najsłabszy wynik